

Workshop Orange DM

LLO

June 4, 2026



Vandaag

17:30-17:45 Introductie

17:45-18:15 Tutorial Orange, Iris dataset

18:15-18:45 Decision trees, classification en regression, model evaluation

18:45-20:00 SMS data

20:00-20:10 Ensemble methodes

20:10-20:30 SMS data, wine data

Leeruitkomsten

Aan het eind van de dag kun je:


- Data importeren en voorbereiden in Orange,
- Een model trainen,
- De resultaten evalueren.

Daarnaast begrijp je de typische onderdelen van de machine learning pipeline.


Vormen van machine learning

- Klassificatie vs. Regressie
- Supervised vs. Unsupervised leren
- Batch vs online leren

Decision tree (beslisboom)



Orange DM



Iris dataset

iris setosa



petal

sepal

iris versicolor



petal

sepal

iris virginica




petal


sepal

Go to https://github.com/OnnoHuygen/orange_workshop/ and start on the Iris dataset exercise.

Pipeline



Crisp-DM



Model trainen

Wat hebben we nodig om een model te trainen?

- Data
- Een model

Model trainen

Wat hebben we nodig om een model te trainen?

- Data
- Een model
- Prestatiemaat/kostenfunctie

Voorbeeld: lineaire regressie.

Prestatie meten - prestatiemaat

$$RMSE(\mathbf{X}, h) = \sqrt{\frac{1}{m} \sum_{i=1}^m (h(\mathbf{x}^{(i)}) - y^{(i)})^2}$$


$$MSE(\mathbf{X}, h) = \frac{1}{m} \sum_{i=1}^m (h(\mathbf{x}^{(i)}) - y^{(i)})^2$$

~~$$ME(\mathbf{X}, h) = \frac{1}{m} \sum_{i=1}^m (h(\mathbf{x}^{(i)}) - y^{(i)})$$~~

$$MAE(\mathbf{X}, h) = \frac{1}{m} \sum_{i=1}^m |h(\mathbf{x}^{(i)}) - y^{(i)}|$$

Wat zijn goede redenen voor het kiezen van een bepaalde maat?


Klassificatie



Casus 1


- Dataset met een **miljoen** foto's van gezonde huid en huidkanker
- We trainen een klassificatiemodel op de dataset. Het model haalt een accuracy (accuraatheid) van 95%.
- Het model wordt ingezet in een ziekenhuis, en haalt daar maar een accurateid van 43%.

Wat kan hier mis zijn gegaan?



Modellen trainen: cross-validatie

- Waarom is het nodig om de data te splitsen?



Casus 2

- Dataset met een **miljoen** plaatjes van gezonde huid en huid met kanker
- Data wordt gesplitst in een train en een test set.
- Accuraatheid op de train set: 0.95.
- Accuraatheid op de test set: 0.95.
- Model toegepast in een ziekenhuis, maar **geen enkele** tumor gevonden...

Data schoonmaken - Imputatie


- Wanneer kunnen we missende data aan
- Imputatie van mediaan? Of van gemid
- Wat zijn andere mogelijkheden?



Preprocessing - One hot encoding

- Verschil categorical en ordinal data?
- Wanneer one-hot encoding?
- En wanneer ordinale encoding?
- Nog andere encodings?


id	color
1	red
2	blue
3	green
4	blue



id	color_red	color_blue	color_green
1	1	0	0
2	0	1	0
3	0	0	1
4	0	1	0


Preprocessing - Data schalen

- Wanneer data schalen?
- StandardScaler, andere opties?



Preprocessing - Data schalen

- Wanneer data schalen?
- StandardScaler, andere opties?
- Lange staart? $\Rightarrow$ log schaling.




Modellen trainen - fine-tuning

- Verschil parameters en hyperparameters?
- Verschil grid search en random search?

```
from sklearn.model_selection import GridSearchCV  
  
full_pipeline = Pipeline({
```

```
    {"preprocessing", preprocessing},  
    {"random_forest", RandomForestRegressor(random_state=42)},  
})  
param_grid = [  
    {"preprocessing__geo_n_clusters": [5, 8, 10],  
     "random_forest__max_features": [4, 6, 8]},  
    {"preprocessing__geo_n_clusters": [10, 15],  
     "random_forest__max_features": [6, 8, 10]},  
]  
grid_search = GridSearchCV(full_pipeline, param_grid, cv=3,  
                           scoring='neg_root_mean_squared_error')  
grid_search.fit(housing, housing_labels)
```

Ensemble models



Enquête

Evaluatie Workshop Data-analyse
en Machine Learning in Orange

